

UNIVERSIDAD DEL VALLE DE GUATEMALA

DATAS, sección 20



Lab # 3

Julio García Salas – 22076

Sofía García – 22210

Joaquín Campos – 22155

Guatemala, Julio 2025

Informe del Laboratorio: Comparación de Modelos

1. Análisis exploratorio de datos

El conjunto de datos utilizado pertenece a la colección **PolyMNIST (MMNIST)**, que contiene imágenes de dígitos del 0 al 9 con diferentes tipos de distorsión o modificación, organizadas por modalidad (m0, m1, m2, m3, m4).

- **Total de imágenes:** 350,000
 - **Entrenamiento:** 300,000
 - **Prueba:** 50,000
- **Modalidades:** 5 en total (70,000 imágenes cada una)
- **Tamaño de cada imagen:** 28×28 píxeles
- **Formato:** imágenes a color (3 canales)

Las etiquetas de cada imagen se extraen directamente del nombre del archivo. Cada imagen tiene una etiqueta de clase del 0 al 9. El conjunto de datos está **balanceado**, es decir, hay aproximadamente la misma cantidad de imágenes para cada clase.

2. Modelos utilizados

Se probaron dos modelos de redes neuronales convolucionales (CNN) que varían en complejidad:

Modelo 1: CNN Lite

- Arquitectura más sencilla, con menos capas.
- Entrenamiento más rápido.
- Menor capacidad para capturar variaciones complejas entre imágenes.
- Sirve como punto de partida para evaluar mejoras.

Modelo 2: CNN Deep

- Arquitectura más profunda, con bloques de convolución + batch normalization + ReLU.
- Incluye capas de regularización (dropout).
- Mejora en la capacidad del modelo para reconocer patrones más variados.

- Esperado que tenga mejor desempeño sobre conjuntos con distorsiones.

Ambos modelos fueron entrenados con el mismo conjunto de datos y evaluados con los mismos criterios.

3. Evaluación del desempeño

Se evaluó la precisión de cada modelo utilizando una matriz de confusión y gráficos de conteo por clase. Los resultados reflejan qué tan bien cada modelo logró predecir la etiqueta correcta de los dígitos.

Resultados principales:

- **CNN Lite:**
 - Menor precisión general.
 - Comete errores frecuentes en dígitos con trazos similares (por ejemplo, 4 y 9).
 - Predicciones más dispersas, menos consistentes.
- **CNN Deep:**
 - Precisión superior a la del modelo Lite.
 - Mejora notable en las clases más difíciles.
 - Menos errores repetitivos.
 - Su matriz de confusión muestra mayor concentración en la diagonal (lo que indica aciertos).

4. Prueba con imágenes externas manuscritas

Además de las imágenes del dataset, se probaron ambos modelos con imágenes manuscritas externas generadas por el grupo. Se aplicaron varios pasos para adaptar las imágenes al formato esperado por el modelo:

- Escala de grises
- Inversión de colores
- Binarización (para eliminar ruido de fondo)
- Centrado automático
- Filtro de cierre (para unir trazos rotos)

El modelo que se utilizó para esta prueba fue CNN Deep. Al probarlo con imágenes manuscritas reales, su desempeño inicial fue **de 23.33% de aciertos**, pero luego de aplicar el preprocesamiento subió hasta un **40% de efectividad**. Esto confirma que un buen preprocesamiento de los datos puede marcar una diferencia importante.


5. Conclusión general

- El análisis comparativo muestra que el modelo **CNN Deep** tiene un desempeño superior y es más confiable en tareas reales.
- La diferencia entre los modelos refleja claramente el impacto de la arquitectura en la capacidad del modelo para generalizar.
- El preprocesamiento juega un rol crucial: sin él, incluso el mejor modelo falla en reconocer datos externos.
- Las pruebas con imágenes digitales generadas por código también permitieron observar qué tan sensible es el modelo al estilo visual de los datos.


En resumen, un modelo más complejo como CNN Deep ofrece mejores resultados, pero debe ser alimentado con datos que tengan un estilo visual cercano al que vio durante su entrenamiento. El preprocesamiento puede ayudar a cerrar esa brecha, y es fundamental para cualquier aplicación práctica del modelo.

ANEXO

CNN_Lite_AUG — Confusion matrix (counts)



CNN_Lite_AUG — Confusion matrix (normalized)



CNN_Deep_AUG — Confusion matrix (normalized)

